

News Diff

Coleta e Análise de Notícias com LCS

Pedro Reis · Gabriel Martins

O Problema

Jornalismo na era digital

O que acontece

- G1, Folha, CNN Brasil e outros publicam a mesma notícia com pequenas variações no título;
- Uma notícia vira 5 matérias diferentes em portais distintos;
- O leitor vê o mesmo assunto repetido sem saber que é republicação.

O Problema

Jornalismo na era digital

O que queremos detectar

- Mesma pauta, 3 portais diferentes.

"Neil Sedaka morre aos 86 anos" (Exame)

"Morre Neil Sedaka, cantor, aos 86 anos" (CNN Brasil)

"Neil Sedaka, ícone do pop, morre" (Folha)

Solução Proposta

Pipeline de coleta, filtragem e agrupamento



Estrutura do Projeto

4 módulos, zero dependências externas ao RSS

lcs.py

Núcleo algorítmico

Implementa LCS com DP, backtrack e similaridade normalizada

coletor.py

Coleta de dados

Busca feeds RSS, parse de XML, limpeza de HTML, cache JSON

analizador.py

Agrupamento

Filtra templates, deduplica URLs, executa LCS com pré-filtro

main.py

Interface CLI

Menu interativo: coletar agora, offline, salvar snapshot

O Algoritmo LCS

Longest Common Subsequence via Programação Dinâmica

O que é LCS?

- Encontra a maior subsequência de elementos comum a duas sequências;
- Não precisa ser contígua;
- Normalização: $\text{similaridade} = \text{LCS} / \max(|A|, |B|)$.

Programação Dinâmica

Por que PD e não força bruta?

Complexidade

Força Bruta


$O(2^n)$ — enumera todas as subsequências

Programação Dinâmica

$O(m \times n)$ tempo e espaço

Otimização: Pré-filtro

Evitar LCS desnecessário com interseção de conjuntos



Otimizações

Deduplicação por URL

Remove notícias com mesma URL antes do agrupamento. Evita comparações redundantes.

Filtro editorial

Descarta títulos com padrão de template (ex: 'VÍDEOS:', 'assista aos telejornais'). Elimina ruído do G1.

Cache de palavras-chave

Cada título é tokenizado uma única vez. Resultado fica em cache durante toda a sessão.

Coleta de Dados

28 portais via RSS — sem scraping

Categoria	Portais
Brasil — Geral	G1, Folha, IG
Brasil — Economia	InfoMoney, Exame, MoneyTimes, Investing Brasil
Brasil — Tecnologia	Canaltech, Olhar Digital, Tecnoblog
Brasil — Ciência	Superinteressante
Internacional	BBC, BBC Brasil, CNN Brasil, The Guardian, Al Jazeera, NYT, WaPo
Tech Internacional	TechCrunch, Wired, Ars Technica, MIT Tech Review
Finanças	Financial Times, CNBC, MarketWatch
Entretenimento	Rolling Stone, Variety, The Hollywood Reporter

Interface do Usuário

Menu interativo no terminal

Menu principal

NEWS DIFF

1. Coletar notícias agora
2. Usar snapshot (offline)
3. Coletar e salvar snapshot

0. Sair

Escolha uma opção: _

Parâmetros configuráveis

- Janela de horas (padrão: 5)
- Top N resultados (padrão: 10)
- Arquivo de snapshot para salvar/carregar

Enter aceita o valor padrão

Saída do Sistema

Exemplo real de execução

1. Neil Sedaka, ícone do rock e do pop americano, morre aos 86 anos
Republicada 4x (Exame, Folha, CNN Brasil, G1)
<https://exame.com/pop/neil-sedaka-...>
 - Exame – Neil Sedaka, ícone do rock e do pop americano, morre...
 - Folha – Neil Sedaka, cantor e compositor ícone do pop...
 - CNN – Morre Neil Sedaka, cantor e compositor, aos 86 anos
2. Milei tem vitória no Senado e consegue aprovar reforma trabalhista
Republicada 3x (Folha, CNN Brasil, G1)
 - Folha – Milei tem vitória no Senado e consegue aprovar...
 - CNN – Senado da Argentina aprova reforma trabalhista de Milei
 - G1 – Reforma trabalhista de Milei é aprovada no Senado

450 notícias · 389 tópicos únicos · 61 repetições de tópicos

Estatísticas de Processamento

O que o sistema mostra a cada execução

```
Templates descartados: 17  
Pré-filtro bloqueou: 82.379  
LCS executado: 297 vezes  
Total comparações: 82.676
```

Limitações Conhecidas

Honestidade sobre o que o sistema não resolve

Limiar fixo

0.35 é um valor calibrado empiricamente. Títulos muito curtos ou muito longos podem gerar falsos positivos ou negativos.

Feeds quebrados

Portais que retornam 0 notícias consistentemente foram removidos do portais_extra.txt, mas novos feeds podem quebrar de qualquer modo.

Idiomas mistos

PT e EN ficam no mesmo ranking. Não há separação por idioma — o LCS compara tudo.

Resultados Obtidos

Execuções reais realizadas durante o desenvolvimento

- O pré-filtro de interseção de palavras-chave eliminou 99,6% das comparações desnecessárias;
- O algoritmo identificou e agrupou notícias repetidas em diversos portais;
- Foi possível agrupar notícias sobre o mesmo evento mesmo quando publicadas com títulos e detalhes distintos entre os portais;
- Foi possível destacar as notícias de maior impacto no período com base na republicação entre concorrentes.